

UNIVERSIDAD NACIONAL DE INGENIERÍA DEL PERÚ

UNIDAD DE POSTGRADO FACULTAD DE INGENIERÍA
INDUSTRIAL Y DE SISTEMAS

INFORME DE EXAMEN PARCIAL

«FRAMEWORK MULTIAGENTE CON EVALUACIÓN AUTOMÁTICA DE
CRITICIDAD Y TRANSICIÓN SINÉRGICA ENTRE MODOS DE OPERACIÓN
ADAPTATIVOS PARA LA INGENIERÍA DE SOFTWARE»

PILOTO EXPERIMENTAL: MIDDLEWARE DE CRITICIDAD PLAY/PAUSA/STOP SOBRE
TRIAJE DE BUGS (BUGSREPO/BUGZILLA)

PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO EN CIENCIAS
CON MENCIÓN EN INTELIGENCIA ARTIFICIAL

ELABORADO POR:
José Luis Peñaloza Yaurivilca

Curso: Proyecto de Investigación 2 — Examen Parcial

LIMA, PERÚ
JUNIO 2026

1. Introducción

1.1 Problema

La industria de la ingeniería de software transita hacia la **Ingeniería de Software Agéntica**: sistemas multiagente (MAS) basados en LLM que automatizan tareas complejas. Frameworks como MetaGPT, AgentCoder, ChatDev y AutoGen demuestran capacidades sobresalientes, pero operan con **autonomía estática**: el desarrollador elige entre ejecución totalmente autónoma (HOOTL — Human-Out-of-the-Loop) o supervisión humana permanente (HITL — Human-In-the-Loop), sin graduar la autonomía según el riesgo de cada tarea.

Esta carencia obliga a las organizaciones a una elección binaria y subóptima:

1. **Riesgo de “caja negra”**: agentes autónomos maximizan velocidad pero aceptan alucinaciones catastróficas en componentes críticos.
2. **Ineficiencia operativa**: supervisión humana paso a paso limita la escalabilidad en tareas rutinarias de bajo riesgo.

No existe un “tercer camino” implementado donde el sistema opere en modo HOOTL para tareas rutinarias, transite a HOTL (Human-On-the-Loop) en checkpoints estratégicos y se bloquee en HITL antes de acciones irreversibles. La ausencia de **autonomía adaptativa** basada en criterios formales de riesgo constituye la barrera técnica que la tesis propone derribar.

Problema concreto del examen parcial. Como avance experimental hacia el framework completo, este documento aborda un **caso de uso acotado**: el triaje automático de incidencias de software (bug reports) con tres niveles de autonomía operacional mapeados a **play** (ejecución autónoma), **pausa** (abstención / supervisión en checkpoint) y **stop** (interrupción / validación humana obligatoria).

Los frameworks multi-agente actuales (CrewAI, MetaGPT) delegan la decisión final a un LLM sin interceptar la opinión del agente según riesgo operacional. El **Artículo 14 del EU AI Act** exige supervisión humana proporcional con capacidad de interrupción. El problema específico evaluado es:

¿Un middleware de criticidad que intercepta la decisión del agente multi-agente y puede sobreescribirla a PAUSA o STOP según Blast Radius 4D e incertidumbre RAG

reduce el costo operacional (EC, ex-CEPA) manteniendo la calidad de clasificación (F1-STOP) frente a un baseline amnésico y una variante multi-agente con RAG?

1.2 Objetivos

Objetivo general. Diseñar e implementar un framework multiagente con evaluación automática de criticidad y transición sinérgica entre modos operacionales (HOOTL/HOTL/HITL), demostrando mejoras cuantificables en eficiencia operacional y seguridad técnica respecto a frameworks de autonomía estática en la ingeniería de software empresarial.

Objetivo del examen parcial. Diseñar, implementar y evaluar experimentalmente un pipeline reproducible **Baseline** → **Var1 (multi-agente + RAG)** → **Var2 (middleware de criticidad)**, midiendo calidad de clasificación, costo operacional (EC) y métricas extendidas (tokens, HITL, override) sobre datos reales de BugsRepo/Bugzilla. El índice **END** se reporta solo como auxiliar interno, no como métrica principal.

Objetivos específicos del entregable:

ID	Objetivo (plan de tesis)	Objetivo operacional (parcial 3)	Estado
OE1	Modelo tridimensional de criticidad con precisión ≥ 85 % vs. expertos	Blast Radius 4D + fuzzy-lite + incertidumbre RAG; mapeo Bugzilla severity → play/pausa/stop	Eval n=400
OE2	Transición sinérgica HOOTL/HOTL/HITL con preservación de contexto > 95 %	CriticalityMiddleware Gate A/B; 66/400 overrides Gate B (16,5 %)	Validado entregable v2
OE3	Arquitectura multiagente con motor de criticidad y trazabilidad	Pipeline Baseline/Var1/Var2 con RAG pgvector train-only, cache/API trazable	Reproducible
OE4	Validar con benchmarks y casos reales; reducir ≥ 50 % errores críticos	F1-Macro, F1-STOP, EC, ECE, FNR-STOP en BugsRepo n=400; CV 5-fold + hold-out 120; PASO 4 calibración	Completado PASO 0 → 5

1.3 Preguntas de investigación e hipótesis

Pregunta general (plan de tesis). ¿En qué medida un framework multiagente con evaluación automática de criticidad y transición sinérgica entre modos operacionales (HOOTL/HOTL/HITL) mejora los indicadores de eficiencia operacional y seguridad técnica en comparación con frameworks de autonomía estática?

Preguntas e hipótesis del piloto parcial:

#	Pregunta	Hipótesis	Evidencia preliminar
P1	¿Un LLM amnésico supera reglas léxicas?	H1: Sí — señal semántica en descripciones de bugs	Baseline DeepSeek n=400; F1-Macro 0,362
P2	¿Multi-agente + RAG pgvector mejora al Baseline?	H2: Parcial — Var1 piloto solo; fuera piloto abstención	Var1 F1-Macro 0,335 ; FNR-stop 0,967
P3	¿El middleware reduce EC manteniendo F1-STOP?	H3: Sí en v2 — Gate B activo	Var2 F1-STOP 0,391 ; FNR-stop 0,433 ; override 16,5 %
P4	¿La calibración ECE es aceptable?	H4: Mejorable — ECE crudo 0,42–0,45	PASO 4: isotónica reduce ECE a 0,003–0,035 (n=400)

1.4 Variables

Variables conceptuales (plan de tesis):

Tipo	Variable	Definición / niveles
Independiente	Nivel de criticidad evaluado	Bajo / medio / alto (FMEA: Impacto × Probabilidad × Detectabilidad)
Independiente	Modo operacional	HOOTL, HOTL, HITL (mapeados a play, pausa, stop)
Dependiente	Eficiencia operacional	Tiempo de ciclo, intervenciones humanas, throughput
Dependiente	Seguridad técnica	Errores críticos, false negatives en tareas de alto riesgo
Control	Framework comparado	MetaGPT, AutoGen, Devin (modo estático)

Variables operacionalizadas (experimento parcial):

Tipo	Variable	Definición / niveles
Independiente	Variante experimental	Baseline (DeepSeek solo), Var1 (+ CrewAI/RAG), Var2 (+ middleware HPO)

Tipo	Variable	Definición / niveles
Independiente	Parámetros middleware	Pesos 4D, umbrales stop/pausa, modo stop_heavy (sprint7 trial 68)
Dependiente	F1-Macro, F1-STOP, EC, ECE, FNR-stop, MCC-macro	Set mínimo 6 (sklearn + Elkan 2001 + Geifman 2017 + Matthews 1975)
Dependiente	F1-play, F1-pausa, tokens, latencia, HITL USD	Métricas extendidas framework (PASO 3, 8_tabla_metricas_extendidas)
Dependiente	override_rate	Intervención middleware Var2 (EU AI Act Art. 14)
Control	seed, anti-leakage	seed=42; 0 overlap hash test/history

2. Marco teórico

2.1 Fundamentos del plan de tesis

- **Sistemas multiagente (MAS):** orquestadores basados en LLM (MetaGPT, CrewAI, ChatDev). Revisión sistemática reciente: He et al. (2025); encuesta de agentes: Liu et al. (2024). Gap: pocos integran criticidad adaptativa con HITL en tiempo de ejecución (Liu J. et al., 2024, HULA).
- **Supervisión humana adaptativa:** HOOTL (autonomía total), HOTL (checkpoints), HITL (validación paso a paso). Controles PLAY/PAUSE/STOP mapean directamente a modos operacionales.
- **FMEA / ISO 14971 / NASA-STD-8739.8:** evaluación tridimensional Severidad × Ocurrencia × Detección; base del módulo de criticidad propuesto.
- **Trust calibration / calibración LLM:** Fisch et al. (2022); evaluación post-hoc en PASO 4 (isotónica train-only).
- **Design Science Research (DSR):** evaluación de artefacto reproducible según protocolo IA08 UNI; alineado a revisiones de sistemas LMA en SE (He et al., 2025).

2.2 Fundamentos del piloto experimental

Referencia	Aporte al parcial
Chow (1970) <i>vía Chow 1970 / literatura selectiva</i>	Abstención pausa como rechazo controlado (D5)
Elkan (2001) <i>vía cost-sensitive SE 2021–2025</i>	Métrica EC (FN-stop peso 1,0; pausa 0,08; stop 0,18)
Fisch et al. (2022)	Calibración selectiva post-hoc — base PASO 4
Es et al. (2024) RAGAS	Evaluación RAG: faithfulness, relevancia contexto
Mashhadi et al. (2023)	Severidad de bugs con LLM — contexto BugsRepo
EU AI Act (2024) Regl. 2024/1689	HITL proporcional; stop como interrupción
CrewAI / MetaGPT (2024)	Orquestación multi-rol Var1 (Analyst + Reviewer)
He et al. (2025)	Roadmap LMA para ingeniería de software
Liu J. et al. (2024) HULA	HITL en agentes de desarrollo — despliegue industrial
PPT IA04–IA08 (UNI)	Protocolo, CV, ablaciones, cierre examen

3. Datos

3.1 Origen y licencia

Aspecto	Detalle
Fuente primaria	BugsRepo / Bugzilla Eclipse — cache data/external/bugsrepo/bugzilla_eclipse_mapped.csv
Origen alternativo	HuggingFace AliArshad/Bug_Reports_with_Sentiments
	Acharya & Ginde (2025), <i>EASE</i> — BugsRepo

Aspecto	Detalle
Referencia académica	
Licencia	Datasets públicos de investigación; uso académico no comercial con citación obligatoria
Restricción	No redistribuir corpus procesado sin verificar licencia upstream

3.2 Esquema y mapeo de criticidad

Columna	Tipo	Descripción
text	string	Descripción corta del bug (Short Description)
severity	categorical	blocker, critical, major, normal, minor, trivial
resolution	categorical	FIXED, VERIFIED, RESOLVED
product	string	Producto/componente
text_hash	SHA-256	Huella anti-leakage y deduplicación
thesis_class	{play, pausa, stop}	blocker/critical → stop; major/normal → pausa; minor/trivial → play

Nota metodológica: el mapeo Bugzilla severity → play/pausa/stop es un **proxy** de criticidad operacional, no equivalente al modelo FMEA tridimensional de la tesis final.

3.3 Preprocesamiento

Fase	Antes	Después	Detalle
F0 — Campos vacíos	88 682	88 667	Eliminar severity/texto nulo
F1 — Resolution	88 667	88 667	Filtro FIXED
F2 — Enhancement	88 667	88 667	Excluir enhancement
F3 — Dedup SHA-256	88 667	88 008	659 duplicados
F4 — Mapeo criticidad	88 008	88 008	play 5 179 / pausa 76 190 / stop 6 639

3.4 Muestreo, ética y PII

- **Laboratorio (Cochran):** $n \approx 384$ ($Z=1,96$, $E=0,05$, $p=0,5$) → **n=400** eval ejecutado, seed=42.
- **Hold-out:** $n = 120$ (30 % estratificado del muestreo lab).
- **Splits RAG:** history $n=6000$; **0 overlap** hash eval/history.
- **PII:** textos pueden contener rutas/URLs; identificación interna solo por text_hash; no se exportan identificadores de reportero.

Artefactos: 0_etl_ingesta_preprocesamiento/1_embudo_limpieza_por_fases.csv, 8_conjunto_evaluacion_experimento_n400.csv.

4. Protocolo experimental

4.1 Diseño de variantes (ablación simétrica)

#	Variante	Pipeline
1	Baseline	DeepSeek amnésico — sin RAG, sin agentes, sin middleware
2	Var1	CrewAI multi-agente + DeepSeek + RAG pgvector train-only
3	Var2	Var1 + CriticalityMiddleware (intercepta decisión del agente)

Prioridad de fuentes (0_configuracion_protocolo_experimental.yaml): Baseline → **api-incremental DeepSeek** (246 API + 154 cache); Var1 → **40 CrewAI piloto** (cache) + **360 abstención pausa** fuera piloto (Chow 1970); Var2 → Gate B ampliado sobre Var1.

Arquitectura v2 (jun 2026): prompt CrewAI v2_permissive_agent; sin pgvector_majority_fallback; Gate B con umbral FN-stop 0,42 y reglas escalación.

4.2 Validación cruzada y métricas

Nivel	Descripción
A. HPO sprint7	StratifiedKFold $k=5$, $n=600$ calibración; Optuna TPE 160 trials; sin llamadas LLM
B. Eval n=400	StratifiedKFold $k=5$ sobre predicciones cacheadas/API

Nivel	Descripción
C. Holdout 120	Métricas en split disjunto 30 % estratificado

Set mínimo de métricas (6): F1-Macro, F1-STOP, ECE, EC (ex-CEPA), FNR-STOP, MCC-macro. **Extendidas:** override_rate, F1-play/pausa, tokens, latencia, HITL USD (8_tabla_metricas_extendidas_framework_por_variante.csv).

4.3 Espacio HPO ganador (trial 68)

Parámetro	Valor
mode	stop_heavy
threshold_stop	0,64
threshold_pausa	0,20
risk_stop_floor	0,40
p_stop_floor	0,52
stop_cost_threshold	0,46
pause_uncertainty	0,38
Pesos base/risk/p_stop/uncertainty/rag_gap/fuzzy_stop	0,287 / 0,231 / 0,103 / 0,142 / 0,052 / 0,185

Nota: trial podado en fold 3/5; objetivo CV parcial 0,884.

4.4 Ejecución real vs. cache (honestidad metodológica)

Componente	Estado
Baseline DeepSeek	246 API real + 154 cache (400/400, 0 fallback léxico)
Var1 CrewAI+RAG	40 CrewAI cache (piloto D5) + 360 abstención pausa
Var2 Middleware	Gate B ampliado; 66 overrides (16,5 %)
RAG pgvector	Real Docker entregable_rag, train-only

Componente	Estado
API DeepSeek	246 llamadas exitosas , 0 errores crédito/rate-limit

Salvedad D5: Var1 no ejecuta CrewAI en los 400 tickets. El diseño fija cobertura mínima del **10 %** (n=40 estratificado, seed=42) con **90 % abstención conservadora a pausa** fuera del piloto (Chow 1970). Esto es **intencional**, no un fallo de implementación. La **contribución principal** del parcial es **Var2** (middleware Gate B).

5. Ingeniería de atributos

El middleware Var2 combina señales deterministas post-RAG:

Componente	Función	Implementación
Blast Radius 4D	I_db, I_mem, I_sec, I_dat	compute_risk_score_4d_en
Fuzzy-lite	Reglas lingüísticas stop/pausa	criticidad_var3_camino_b_lite
Incertidumbre RAG	Entropía vecinos + distancia pgvector	k=5, SVD 64D
Conformal-lite	Umbral calibrados train-only	Calibración n=600, sprint7
Agregación	Score ponderado → play/pausa/stop	Pesos HPO normalizados

RAG (PASO 1): TF-IDF + SVD 64D; recuperación híbrida pgvector con k=5 vecinos; history n=6000 train-only; anti-fuga verificada (4_informe_auditoria_anti_fuga.json).

Comportamiento en eval n=400: Var2 altera **66/400** predicciones Var1 vía Gate B (override_rate 16,5 %). Var1 piloto: **40 predicciones CrewAI** reales; fuera piloto abstención conservadora a pausa.

6. Resultados de validación

6.1 Eval n=400 — set mínimo (fuente:


7_tabla_metricas_set_minimo_seis_por_variante.csv)

Variante	F1-Macro	F1-STOP	ECE	EC	FNR-STOP	Override
Baseline DeepSeek	0,3623	0,3008	0,4478	0,1106	0,3333	—
Var1 CrewAI+RAG	0,3353	0,0571	0,4400	0,1468	0,9667	0 %
Var2 Middleware	0,4353	0,3908	0,4193	0,1232	0,4333	16,5 %

Lectura: Var2 supera Baseline en F1-macro y F1-STOP; Var1 fuera piloto colapsa en detección stop (FNR 97 %) — demuestra necesidad del middleware.


6.1.1 Figuras esenciales

Figura 1. Ablación F1-macro, EC y FNR-stop por variante (PASO 3).




Fuente: 3_protocolo_experimental_variantes/13_figura_ablacion_f1_macro_ec_fnr_stop.png. Var2 mejora F1-stop y FNR-stop respecto a Baseline y Var1.

Figura 2. Matrices de confusión 3×3 — Baseline, Var1 y Var2 (n=400).




Fuente: 14_figura_matrices_confusion_tres_variantes.png. Var1 concentra predicciones en pausa (abstención D5); Var2 recupera clase stop.

Figura 3. Curvas de calibración y ECE antes/después de isotónica (PASO 4).




Fuente: 4_calibracion_diagnosticos_y_explicabilidad/2_figura_curvas_calibracion_tres_variantes.png. ECE cae de ~0,42–0,45 a 0,003–0,035 en $n=400$.

Figura 4. Ablación por componente del middleware — $\Delta F1$ -stop y ΔEC .



Fuente: 4_figura_ablacion_delta_f1_stop_ec.png. Apagar Gate B (sin_gate_b) reduce F1-stop en 0,334 puntos.

Figura 5. Importancia de señales en overrides Gate B (66 casos).



Fuente: 6_figura_importancia_senales_gate_b.png. Top: incertidumbre RAG, consenso de clase, impacto memoria (I_mem).

6.2 Métricas extendidas (framework)

Variante	F1-play	F1-pausa	tokens	lat. media ms	HITL USD
Baseline	0,144	0,642	80 358	0	2 280
Var1	0,068	0,881	38 364	305	1 425
Var2	0,048	0,867	38 364	306	2 222

6.3 Hold-out n=120

Variante	F1-Macro	F1-STOP	EC	FNR-STOP
Baseline	0,3709	0,3256	0,1050	0,2222
Var1	0,3095	0,0000	0,1550	1,0000

Variante	F1-Macro	F1-STOP	EC	FNR-STOP
Var2	0,4691	0,5000	0,1125	0,2222

6.4 Validación cruzada 5-fold

(10_tabla_validacion_cruzada_5fold_estratificada_n400.csv)

Variante	F1-Macro ($\mu \pm \sigma$)	F1-STOP ($\mu \pm \sigma$)	EC ($\mu \pm \sigma$)
Baseline	0,3589 $\pm$ 0,0569	0,3042 $\pm$ 0,1062	0,1106 $\pm$ 0,0170
Var1	0,3316 $\pm$ 0,0541	0,0556 $\pm$ 0,1111	0,1468 $\pm$ 0,0082
Var2	0,4318 $\pm$ 0,0612	0,3889 $\pm$ 0,0954	0,1232 $\pm$ 0,0115

6.5 Calibración y ablaciones (PASO 4)

Análisis	Resultado principal
Calibración isotónica (fit train 280)	Baseline ECE 0,448 $\rightarrow$ 0,003 ; Var1 0,440 $\rightarrow$ 0,035 ; Var2 0,419 $\rightarrow$ 0,026 (n=400)
Brier	Baseline 0,405 $\rightarrow$ 0,250; Var2 0,300 $\rightarrow$ 0,176
Ablación Gate B	sin_gate_b: Δ F1-stop -0,334 (F1-stop 0,057) — confirma valor middleware
Ablación RAG	sin_senal_rag: override 13 % vs 16,5 %; EC -0,003
Explicabilidad overrides	Top señales: rag_uncertainty, class_consensus, I_mem (permutation importance, 66 overrides)
Sub-análisis piloto n=40	Var1 solo CrewAI: F1-macro 0,119; F1-stop 0,25; FNR-stop 0,67 — no generalizable a n=400

6.6 Comparación pareada (McNemar)

Par	Acuerdo	Nota
Baseline vs Var1	46,8 %	p nominal < 0,05
Var1 vs Var2	83,5 %	61 discordancias; p nominal 0,877 (no significativo)

Par	Acuerdo	Nota
Baseline vs Var2	52,8 %	p nominal < 0,05

Limitación: clases raras (stop n=30) limitan poder estadístico de McNemar.

6.7 Tablero consolidado (PASO 5)

Ítem	Resultado
Experimentos registrados	13 corridas (1_tablero_experimentos_consolidado.csv)
Checklist IA08	27/27 ítems CUMPLIDO (100 %)
Gap F1-stop Var2 eval vs holdout	0,391 vs 0,500 — generalización favorable
Gap ECE isotónica holdout	Var2: 0,026 (n=400) vs 0,087 (holdout) — monitorear despliegue (3_informe_gap_overfitting_calibracion.json)
Veredicto global	APROBADO (6_veredicto_final_entregable.md)

7. Análisis

7.1 Riesgos metodológicos

Riesgo	Descripción	Mitigación aplicada
Piloto CrewAI 10 % (D5)	Var1 solo ejecuta CrewAI en n=40; 360 tickets con abstención pausa	Documentado como diseño Chow 1970; sub-análisis n=40 separado
Proxy Bugzilla	Severity ≠ riesgo operacional real	Transparente en informe; tesis final usará FMEA tridimensional
n_stop=30	Bajo poder estadístico McNemar en clase stop	Reportar CV 5-fold + holdout; no extrapolar significancia
HITL cost supuesto	5 min/pausa, 20 min/stop, \$45/h dev	Marcado como supuesto en 8_tabla_metricas_extendidas

Riesgo	Descripción	Mitigación aplicada
Calibración isotónica	ECE holdout > n400 en Var1/Var2	Validar en holdout antes de despliegue (PASO 4)
Anti-leakage	Fuga train → eval en RAG	Auditoría 0 overlap hash; fit TF-IDF train-only

7.2 Conclusiones

1. Pipeline **reproducible** Baseline → Var1 → Var2 con datos BugsRepo reales, API DeepSeek y auditoría doble (PASO 0 → 5).
2. **Var2** supera Baseline en F1-macro (0,435 vs 0,362) y F1-STOP (0,391 vs 0,301) — **H3 confirmada** en arquitectura v2.
3. **Var1** piloto demuestra límite sin middleware (FNR-stop 97 % fuera piloto con abstención).
4. Ablación `sin_gate_b` confirma que el middleware es el componente crítico ($\Delta F1\text{-stop} -0,334$).
5. Calibración isotónica reduce ECE de 0,42–0,45 a 0,003–0,035 en n=400; gap holdout documentado.
6. Checklist IA08 **100 %** cumplido; veredicto global **APROBADO**.

8. Trabajo futuro

1. **Extender CrewAI >10 %** con presupuesto API controlado; evaluar prompt restrictivo vs permisivo.
2. **Experimento MetaGPT separado** como variante adicional (no mezclado con CrewAI piloto).
3. **Modelo FMEA tridimensional** con validación experta (objetivo OE1 ≥ 85 % precisión).
4. **Transición sinérgica HOOTL/HOTL/HITL** con preservación de contexto en tareas de código (HumanEval/MBPP).
5. **Calibración en producción:** monitorear ECE holdout y re-calibrar con datos nuevos.
6. **Despliegue MLOps:** integrar tablero PASO 5 con pipeline CI/CD y alertas de drift.

9. Referencias

Criterio del curso: priorizar literatura 2021–2026 (≤ 5 años). Conceptos clásicos (Chow 1970, Elkan 2001) se citan vía revisiones recientes.

9.1 Referencias principales (2021–2026)

- Acharya, A. & Ginde, G. (2025). BugsRepo: A Large-scale Repository of Bug Reports. *Proceedings of the 29th International Conference on Evaluation and Assessment in Software Engineering (EASE)*.
- Chen, Y., et al. (2025). A retrieval-augmented LLM framework for severity prediction of bug reports in cloud-based mobile applications. *Journal of Cloud Computing*, 14, Article 8. <https://doi.org/10.1186/s13677-025-00826-w>
- Dervişoğlu, H., Halepmollası, R., & Eyvaz, E. (2025). Privacy-Preserving Methods for Bug Severity Prediction. *EASE 2025*. arXiv:2506.22752.
- Es, S., et al. (2024). RAGAS: Automated Evaluation of Retrieval Augmented Generation. *EACL 2024 — System Demonstrations*, 150–158. arXiv:2309.15217.
- European Union (2024). Reglamento (UE) 2024/1689 — *Artificial Intelligence Act* (EU AI Act), Art. 14 (supervisión humana).
- Fisch, A., et al. (2022). Calibrated Selective Classification. *NeurIPS 2022*.
- He, J., Treude, C., & Lo, D. (2025). LLM-Based Multi-Agent Systems for Software Engineering: Literature Review, Vision and the Road Ahead. *ACM Transactions on Software Engineering and Methodology*. doi:10.1145/3712003.
- Hong, H., et al. (2024). MetaGPT: Meta Programming for a Multi-Agent Collaborative Framework. *ICLR 2024*.
- Huang, J., et al. (2024). AgentCoder: Multi-Agent Code Generation Framework. *Transactions on Machine Learning Research*.
- Liu, J., et al. (2024). Human-In-the-Loop Software Development Agents (HULA). arXiv:2411.12924.
- Liu, Y., et al. (2024). Large Language Model-Based Agents for Software Engineering: A Survey. arXiv:2409.02977.
- Mashhadi, E., et al. (2023). Method-Level Bug Severity Prediction using Source Code Metrics and LLMs. arXiv:2309.03044.
- Ramay, W., et al. (2024). SevPredict: Exploring the Potential of Large Language Models in Software Maintenance. *AI*, 5(4), 2739–2760. doi:10.3390/ai5040132.

- Material PPT IA04–IA08 — Maestría en Inteligencia Artificial, UNI (protocolo experimental, CV, calibración, cierre examen parcial).

9.2 Conceptos base (anteriores a 2021 — citados en revisiones §9.1)

- Chow, C.K. (1970). On optimum recognition error and reject tradeoff. *IEEE Trans. Information Theory* — abstención pausa (D5).
 - Elkan, C. (2001). The foundations of cost-sensitive learning. *ICML* — matriz de costos EC.
 - Geifman, Y. & El-Yaniv, R. (2017). Selective classification for deep neural networks. *NeurIPS* — ECE y rechazo selectivo.
-

Anexos — Rutas de artefactos del entregable

PASO 0 — ETL e ingesta

- 0_etl_ingesta_preprocesamiento/0_etl_datos_limpieza_y_muestreo.ipynb
- 0_etl_ingesta_preprocesamiento/1_embudo_limpieza_por_fases.csv
- 0_etl_ingesta_preprocesamiento/
8_conjunto_evaluacion_experimento_n400.csv

PASO 1 — Ingeniería de atributos y RAG

- 1_ingenieria_atributos_y_recuperacion_rag/
1_ingenieria_atributos_y_rag.ipynb
- 1_ingenieria_atributos_y_recuperacion_rag/
3_tabla_vecinos_recuperados_top5.csv
- 1_ingenieria_atributos_y_recuperacion_rag/
4_informe_auditoria_anti_fuga.json

PASO 2 — Módulo criticidad

- 2_modulo_criticidad_gobernanza_adaptativa/
2_modulo_criticidad_gobernanza_adaptativa.ipynb
- 2_modulo_criticidad_gobernanza_adaptativa/
4_tabla_decisiones_gate_b_post_agente_simulado_n400.csv

- 2_modulo_criticidad_gobernanza_adaptativa/
6_tabla_metricas_modulo_criticidad_capa_a.csv

PASO 3 — Protocolo experimental

- 3_protocolo_experimental_variantes/
3_protocolo_experimental_baseline_var1_var2.ipynb (ejecutado;
visualizaciones inline)
- 3_protocolo_experimental_variantes/
7_tabla_metricas_set_minimo_seis_por_variante.csv
- 3_protocolo_experimental_variantes/
8_tabla_metricas_extendidas_framework_por_variante.csv
- 3_protocolo_experimental_variantes/
9_tabla_validacion_holdout_30_por_variante.csv
- 3_protocolo_experimental_variantes/
10_tabla_validacion_cruzada_5fold_estratificada_n400.csv
- 3_protocolo_experimental_variantes/
11_tabla_comparacion_pareada_mcnemar.csv
- 3_protocolo_experimental_variantes/
13_figura_ablacion_f1_macro_ec_fnr_stop.png
- 3_protocolo_experimental_variantes/
14_figura_matrices_confusion_tres_variantes.png

PASO 4 — Calibración y explicabilidad

- 4_calibracion_diagnostics_y_explicabilidad/
1_tabla_calibracion_ece_brier_antes_despues.csv
- 4_calibracion_diagnostics_y_explicabilidad/
3_tabla_ablacion_componentes_middleware.csv
- 4_calibracion_diagnostics_y_explicabilidad/
7_tabla_metricas_piloto_crewai_n40.csv
- 4_calibracion_diagnostics_y_explicabilidad/
8_informe_resumen_paso4.json

PASO 5 — Cierre examen parcial MLOps

- 5_cierre_examen_parcial_mlops/1_tablero_experimentos_consolidado.csv

- 5_cierre_examen_parcial_mlops/2_checklist_examen_final_ia08.csv
- 5_cierre_examen_parcial_mlops/
3_informe_gap_overfitting_calibracion.json
- 5_cierre_examen_parcial_mlops/6_veredicto_final_entregable.md

Documentación de referencia

- tesis2/parcial3/TESIS.pdf (plan de tesis de referencia)